



RÉPUBLIQUE TUNISIENNE
Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique
Université de Carthage
Institut National des Sciences Appliquées
et de Technologie



Projet Professionnel Personnel

dans le cadre du

Diplôme National d'Ingénieur en Sciences Appliquées et Technologies

Spécialité : Réseaux Informatiques et Télécommunications

Diagnostic de la maladie d'Alzheimer par analyse des signaux EEG : Comparaison des approches ML et DL

Préparé par

Eya Bargouth

aya.barghouth@insat.ucar.tn

Mariem Elabed

mariem.elabed@insat.ucar.tn

Zemni Rihab

rihab.zemni@insat.ucar.tn

Ferdawes Benali

ferdawes.benali@insat.ucar.tn

Dr. Wided Miled Souid

Encadrante à l'INSAT

Remerciements

Nous tenons à exprimer notre profonde gratitude à notre encadrante, **Mme Wided Miled Soud**, pour son accompagnement scientifique tout au long de ce projet. Sa disponibilité, sa rigueur méthodologique et ses conseils avisés nous ont permis de surmonter les difficultés techniques et de donner le meilleur de nous-mêmes.

Résumé

Ce rapport présente un projet de détection automatique de la maladie d’Alzheimer et de la démence fronto-temporale (FTD) à partir de signaux électroencéphalographiques (EEG) en repos yeux fermés. Les données utilisées proviennent du dataset public OpenNeuro ds004504, qui regroupe 88 sujets répartis en trois groupes cliniques : Alzheimer (A, $n = 36$), démence fronto-temporale (FTD, $n = 23$) et sujets contrôles sains (C, $n = 29$). Le projet explore deux approches différentes. La première, présentée dans le chapitre 1, est une approche Machine Learning classique reposant sur l’extraction manuelle d’un vecteur de caractéristiques multi-domaines (spectrales, temporelles, non-linéaires, cohérences) et l’évaluation de quatre classifieurs — SVM, KNN, Random Forest et XGBoost — . La seconde approche, décrite au chapitre 2, est une méthode hybride Deep Learning–SVM inspirée d’un travail de recherche récent, combinant un auto-encodeur convolutif 1D pour l’extraction de représentations profondes et un SVM à noyau RBF pour la décision finale.

Mots clés : Électroencéphalographie, Maladie d’Alzheimer, Démence fronto-temporale, Apprentissage automatique, Apprentissage profond, Classification binaire, Extraction de caractéristiques, Analyse en composantes principales.

Table des matières

Liste des acronymes	vi
Introduction générale	1
1 Approche Machine Learning	2
1.1 Matériels et méthodes	2
1.1.1 Dataset et prétraitement	2
1.1.1.1 Description du dataset	2
1.1.1.2 Protocole d'acquisition	3
1.1.1.3 Prétraitement	3
1.1.2 Extraction des features	3
1.1.3 Modèles de classification	6
1.1.4 Réduction dimensionnelle	6
1.1.5 Optimisation des hyperparamètres	7
1.2 Résultats	7
1.2.1 Performances des modèles Tuned avec les features retenus après PCA (21 features)	7
1.2.2 Performances des modèles Tuned avec le jeu de données complet (316 features / sans PCA)	9
1.2.3 Importance des features : analyse du meilleur modèle par configuration	10
1.2.3.1 Configuration complète (316 features) — XGBoost Tuned.	10
1.2.3.2 Configuration PCA (21 composantes) — SVM Tuned.	11
1.3 Discussion	12
1.3.1 Complémentarité modèle–dimensionnalité :	12
1.3.2 Points forts	13
1.3.3 Limites et perspectives	13
2 Approche hybride Deep Learning–SVM	14
2.1 Objectifs	14
2.2 Présentation de la solution proposée	14
2.2.1 Architecture globale	14

2.2.2	Étape 1 — Prétraitement	15
2.2.3	Étape 2A — Features handcrafted	15
2.2.3.1	Entropie spectrale (SE)	16
2.2.3.2	Cohérence alpha inter-hémisphérique (MAC)	16
2.2.4	Étape 2B — 1D-CNN pour l'extraction d'embeddings	16
2.2.5	Étape 3 — Fusion, classification et validation	17
2.2.5.1	Normalisation z-score.	17
2.2.5.2	PCA — 64 composantes.	18
2.2.5.3	SMOTE [12].	18
2.2.5.4	SVM-RBF ($C=1$, $\gamma=0,01$).	18
2.2.5.5	Validation croisée imbriquée GroupKFold (5 plis).	18
2.2.6	Explicabilité par SHAP	18
2.3	Résultats et discussion	19
2.3.1	Performances de classification	19
2.3.2	Importance des caractéristiques	19
2.3.3	Analyse comparative des performances	20
2.3.4	Discussion et validation clinique	20
2.3.5	Points forts	22
2.3.6	Limites et perspectives	22
2.4	Conclusion	22
	Conclusion générale et perspectives	23

Table des figures

1.1	Placement des 19 électrodes selon le système 10–20 avec références auriculaires A1 et A2.	3
1.2	Pipeline d'extraction des features EEG.	4
1.3	Barplots comparatifs des performances — PCA features (21) + modèles Tuned.	8
1.4	Matrice de confusion du meilleur modèle — SVM PCA+Tuned	9
1.5	Barplots comparatifs des performances — Jeu de données complet + modèles tuned.	10
1.6	Top 20 features par gain de split — XGBoost Tuned (316 features).	11
1.7	Top 20 features originales par projection PCA — SVM PCA+Tuned.	12
2.1	Architecture globale du pipeline hybride Deep-SVM, inspirée de [12].	15
2.2	Architecture 1D-CNN pour l'extraction d'embeddings (128 dims), inspirée de [12].	17
2.3	Pipeline de fusion, normalisation, rééquilibrage et classification [12].	17
2.4	Explicabilité SHAP : Importance globale des composantes sur l'ensemble des diagnostics.	19
2.5	Explicabilité SHAP : Impact directionnel (positif/négatif) détaillé par classe diagnostique (AD, FTD, CN).	20
2.6	Dynamique temporelle de l'importance SHAP sur une époque de 4 secondes pour chaque classe.	21
2.7	Cartographie topographique de l'attention du modèle. Les zones en rouge sombre indiquent les régions cérébrales les plus déterminantes pour la classification. . . .	21

Liste des tableaux

1.1	Vecteur de caractéristiques multi-domaines : décomposition par niveau de calcul et agrégation.	5
1.2	Comparaison des quatre modèles de classification	6
1.3	Meilleurs hyperparamètres obtenus après optimisation et score de validation croisée.	7
1.4	Performances moyennes (5-fold CV) — Configuration PCA + modèles tuned. . .	8
1.5	Performances moyennes (5-fold CV) — Jeu de données complet + modèles tuned.	9
2.1	Comparaison des performances de classification entre l’implémentation proposée et l’article de référence.	19

Liste des acronymes

- **AD** Alzheimer Disease (Maladie d'Alzheimer)
- **BIDS** Brain Imaging Data Structure
- **CV** Coefficient de Variation
- **DFA** Detrended Fluctuation Analysis
- **DFT ou FTD** Démence Fronto-Temporale
- **DL** Deep Learning (Apprentissage profond)
- **EEG** Électroencéphalographie
- **HFD** Higuchi Fractal Dimension
- **KNN** K-Nearest Neighbors
- **ML** Machine Learning (Apprentissage automatique)
- **PCA** Principal Component Analysis
- **PSD** Power Spectral Density (Densité spectrale de puissance)
- **RF** Random Forest
- **SVD** Singular Value Decomposition
- **SHAP** SHapley Additive exPlanations
- **SMOTE** Synthetic Minority Over-sampling Technique
- **SVM** Support Vector Machine
- **XGBoost** eXtreme Gradient Boosting
- **ZCR** Zero-Crossing Rate

Introduction générale

La maladie d'Alzheimer (AD) constitue la forme la plus répandue de démence, représentant 60 à 70 % des cas et touchant environ 57 millions de personnes en 2021, avec une projection à 153 millions d'ici 2050 [10, 11]. Sur le plan neuropathologique, elle se caractérise par l'accumulation extracellulaire de plaques amyloïdes β et de dégénérescences neurofibrillaires intracellulaires (tau hyperphosphorylée), entraînant une perte synaptique et une atrophie corticale progressive [7]. Ces altérations précèdent de plusieurs décennies l'apparition clinique, ce qui souligne l'enjeu majeur d'un diagnostic précoce.

Les méthodes diagnostiques actuelles — IRM, TEP, ponction lombaire — sont coûteuses, invasives ou d'accès limité. L'EEG se distingue comme une alternative non invasive, peu coûteuse et dotée d'une résolution temporelle à la milliseconde. Des décennies de recherche ont établi que l'AD induit un ralentissement du rythme cérébral (augmentation δ et θ , diminution α et β), une réduction de la cohérence inter-hémisphérique et une perte de complexité non-linéaire [8, 13, 14]. Cependant, la traduction de ces biomarqueurs en systèmes de classification automatique robustes reste un défi ouvert, notamment en raison de la faible taille des cohortes cliniques et de la variabilité inter-individuelle.

Ce projet interroge trois points :

- (i) un vecteur de caractéristiques multi-domaines extrait manuellement permet-il une discrimination cliniquement significative entre patients Alzheimer et sujets sains ?
- (ii) les représentations apprises par un réseau convolutif apportent-elles un gain de performance ?
- (iii) l'optimisation systématique des hyperparamètres compense-t-elle la limitation liée à la faible taille du dataset ?

Chapitre 1

Approche Machine Learning

Introduction

Ce chapitre présente l’approche classique d’apprentissage automatique appliquée à la classification binaire Alzheimer versus sujet contrôle à partir de signaux EEG. Nous décrivons successivement le dataset et le prétraitement, le pipeline d’extraction d’un vecteur de caractéristiques multi-domaines, les modèles de classification évalués, la stratégie de réduction dimensionnelle par PCA, ainsi que l’optimisation des hyperparamètres par recherche aléatoire.

1.1 Matériels et méthodes

1.1.1 Dataset et prétraitement

1.1.1.1 Description du dataset

Les données utilisées proviennent du dataset public OpenNeuro ds004504 (version 1.0.7) [16]. Ce dataset rassemble les enregistrements EEG de repos yeux fermés de 88 sujets répartis en trois groupes cliniques :

- **Groupe A (Alzheimer)** : $n = 36$ sujets ;
- **Groupe F (FTD)** : $n = 23$ sujets ;
- **Groupe C (Contrôles sains)** : $n = 29$ sujets.

Les données sont structurées selon le standard BIDS (Brain Imaging Data Structure) et sont accessibles publiquement via synchronisation S3 ou téléchargement direct.

1.1.1.2 Protocole d'acquisition

Les enregistrements ont été réalisés selon le système international 10–20 avec 19 électrodes de scalp : Fp1, Fp2, F7, F3, Fz, F4, F8, T3, C3, Cz, C4, T4, T5, P3, Pz, P4, T6, O1, O2, avec les références liées aux oreilles A1 et A2 (Figure 1.1) et sont enregistrés à 500 Hz.




Figure 2. Placement of the 19 electrodes.

FIGURE 1.1 – Placement des 19 électrodes selon le système 10–20 avec références auriculaires A1 et A2.

1.1.1.3 Prétraitement

Le prétraitement a été effectué par les auteurs du dataset et les signaux prétraités sont disponibles dans le dossier `derivatives`. Les étapes incluent le rejet d'artefacts oculaires et musculaires, le filtrage passe-bande et la re-référenciation. Dans notre pipeline, chaque fichier `.set` prétraité est chargé via MNE-Python [5], puis segmenté en segments de 4 secondes avec un chevauchement de 50 %. Cette segmentation produit 34 788 segments au total sur l'ensemble des 88 sujets.

1.1.2 Extraction des features

Le vecteur de features est construit selon une approche hybride multi-domaines.




FIGURE 1.2 – Pipeline d'extraction des features EEG.

TABLEAU 1.1 – Vecteur de caractéristiques multi-domaines : décomposition par niveau de calcul et agrégation.

Les colonnes *N. Segment* et *N. Sujet* indiquent la dimension après calcul au niveau segment et celle après agrégation $[\mu, \sigma]$. Le ratio θ/α (2 features) est calculé au niveau segment et fait partie intégrante des 308 features baseline.

Famille (Dim.)	N. Segment	N. Sujet	Feature	Formule / Définition	Ref.
Spectrale (32)	16 4 bandes $\times$ 4 stats	32	Welch PSD	$P_{xx}(f) = \frac{1}{U} \sum_{n=0}^{N-1} w[n] x[n] e^{-j2\pi f n} ^2$, $U = \sum w[n] ^2$; bandes δ (0.5–4), θ (4–8), α (8–13), β (13–30) Hz	[1]
			Puissance absolue	$BP_{[f_{\min}, f_{\max}]} = \sum_{f \in \text{bande}} P_{xx}(f)$; 4 bandes $\times$ 4 stats (abs/rel $\times$ mean/std) par segment	
			Puissance relative	$RP_{\text{bande}} = BP_{\text{bande}} / \sum_f P_{xx}(f)$	
Temporelle (12)	6 3 stats $\times$ 2	12	Variance	$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$; agrégation $[\mu, \sigma]$ par sujet	[2]
			Skewness	$\gamma_1 = \frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \bar{x}}{\sigma}\right)^3$; agrégation $[\mu, \sigma]$ par sujet	
			Kurtosis	$\gamma_2 = \frac{1}{N} \sum_{i=1}^N \left(\frac{x_i - \bar{x}}{\sigma}\right)^4 - 3$; agrégation $[\mu, \sigma]$ par sujet	
SVD globale (2)	1 1 entropie	2	Entropie SVD	$H_{\text{SVD}} = -\sum_i \bar{\lambda}_i \log_2 \bar{\lambda}_i$, $\bar{\lambda}_i = \lambda_i / \sum_j \lambda_j$; décomposition sur la matrice complète ($n_{\text{canaux}} \times n_{\text{échantillons}}$); agrégation $[\mu, \sigma]$ par sujet	[6]
Cohérence (32)	16 [†] 4 paires $\times$ 4 bandes	32	Cohérence spectrale	$C_{xy}(f) = \frac{ S_{xy}(f) ^2}{S_{xx}(f) S_{yy}(f)}$; 4 paires (F3–F4, P3–P4, F3–P3, F4–P4) $\times$ 4 bandes; calcul sur segments concaténés; agrégation $[\mu, \sigma]$	[13]
Non-linéaire (228)	114 19 élec $\times$ 6 métriques	228	Higuchi FD	$L_m(k) = \frac{1}{k} \sum_{i=1}^{\lfloor (N-m)/k \rfloor} x_{m+ik} - x_{m+(i-1)k} $; pente D de $\ln L(k)$ vs $\ln(1/k)$; [12]	
			DFA	Signal intégré $y(k) = \sum_{i=1}^k (x_i - \bar{x})$; pente α de $\ln F(n)$ vs $\ln n$; [3]	
			SVD-Ent (canal)	$H = -\sum_i \bar{\lambda}_i \log_2 \bar{\lambda}_i$ sur la matrice de trajectoire du canal; [6]	
			ZCR	$ZCR = \frac{1}{N} \sum_{i=1}^{N-1} \mathbf{1}_{x_i x_{i+1} < 0}$;	
			Hjorth Mob.	$\text{Mob} = \sigma_{x'}/\sigma_x$; [2]	
			Hjorth Comp.	$\text{Comp} = \text{Mob}_{x'}/\text{Mob}_x$;	
Dérivées (10)	0 post-agrégation	10	Ratios inter-bandes	δ/α , δ/θ , slow-to-fast = $(\delta + \theta)/\alpha$, β/α ; calculés au niveau sujet après agrégation (4)	[14]
			Coeff. variation	$CV = \sigma/\mu$ pour puissances absolues ($\delta, \theta, \alpha, \beta$), HFD et DFA; calculés au niveau sujet après agrégation (6)	
Total					316

[†] La cohérence est calculée une seule fois par sujet sur l'ensemble des segments concaténés (signal continu) pour garantir une résolution fréquentielle robuste dans la bande delta (0.5–4 Hz).

1.1.3 Modèles de classification

Quatre modèles sont évalués en validation croisée stratifiée 5-fold. Chaque modèle est encapsulé dans un Pipeline scikit-learn incluant une standardisation (`StandardScaler`). Les quatre modèles employés sont : **SVM**, **KNN**, **RF** et **XGBoost**. Leur comparaison synthétique est présentée dans le Tableau 1.2.

TABLEAU 1.2 – Comparaison des quatre modèles de classification

Modèle	Paradigme	Forces principales	Régularisation / Paramètres clés
SVM (RBF)	Séparateur à vaste marge avec noyau radial	Efficace en dimension modérée ; frontière non-linéaire globale ; robuste au surapprentissage par maximisation de la marge	C (pénalisation d'erreur), γ (largeur du noyau RBF)
KNN	Méthode non-paramétrique par voisinage	Simple, interprétable ; aucune hypothèse sur la distribution des données	k (nombre de voisins), métrique de distance
RF	Ensemble d'arbres de décision avec bagging	Réduit la variance par agrégation ; robuste aux outliers ; sélection implicite de features	<code>n_estimators</code> , <code>max_depth</code> , <code>max_features</code>
XGBoost	Gradient boosting d'arbres séquentiels	Capture les interactions non-linéaires ; résilient à $p \gg n$; régularisation intégrée L_1/L_2	<code>learning_rate</code> , <code>max_depth</code> , <code>subsample</code> , <code>colsample_bytree</code>

1.1.4 Réduction dimensionnelle

L'Analyse en Composantes Principales (PCA) est une transformation linéaire orthogonale qui projette les données sur un nouvel espace dont les axes — les composantes principales — maximisent successivement la variance expliquée. Mathématiquement, pour une matrice de données centrées $\mathbf{X} \in \mathbb{R}^{n \times p}$, la PCA diagonalise la matrice de covariance empirique $\mathbf{C} = \frac{1}{n-1} \mathbf{X}^\top \mathbf{X}$. Les composantes principales correspondent aux vecteurs propres de $\mathbf{C}$, ordonnés par valeurs propres décroissantes $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$. Le nombre de composantes retenues k est déterminé par le seuil de variance cumulée :

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i} \geq 0.95$$

Dans notre étude, $p = 316$ features et $n = 65$ sujets ; le ratio $p/n \approx 4.9$ favorise le surapprentissage. La PCA réduit la dimension à $k = 21$ composantes tout en conservant 95 % de l'information varianceielle, ce qui débruite l'espace, élimine la multicolinéarité et restaure l'efficacité des métriques à noyau (notamment RBF) qui dégradent en très haute dimension par concentration de la mesure. [4].

1.1.5 Optimisation des hyperparamètres

L'optimisation est conduite par `RandomizedSearchCV` (50 itérations, validation croisée 5-fold) sur le jeu complet de 316 features. Les grilles de recherche couvrent les paramètres structuraux et de régularisation de chaque modèle. La validation croisée est **stratifiée K -fold** ($K = 5$) : chaque pli préserve la proportion des classes du jeu original, ce qui est essentiel face au déséquilibre (36 AD vs 29 contrôles).

TABLEAU 1.3 – Meilleurs hyperparamètres obtenus après optimisation et score de validation croisée.

Modèle	Paramètre	Valeur optimale
XGBoost	<code>max_depth</code>	4
	<code>n_estimators</code>	351
	<code>learning_rate</code>	0.2503
	<code>subsample</code>	0.8428
	<code>colsample_bytree</code>	0.7555
	<code>min_child_weight</code>	1
	<code>gamma</code>	0.1357
RF	<code>n_estimators</code>	225
	<code>max_depth</code>	None
	<code>min_samples_split</code>	2
	<code>min_samples_leaf</code>	1
	<code>max_features</code>	log2
SVM	<code>C</code>	97.2712
	<code>gamma</code>	scale
	<code>kernel</code>	rbf
	<code>degree</code>	4
KNN	<code>n_neighbors</code>	17
	<code>weights</code>	uniform
	<code>metric</code>	minkowski
	<code>p</code>	2
	<code>leaf_size</code>	25

1.2 Résultats

1.2.1 Performances des modèles Tuned avec les features retenus après PCA (21 features)

Le Tableau 1.4 synthétise les performances des quatre modèles après réduction PCA conservant 95 % de la variance. Le SVM à noyau RBF émerge comme le classifieur optimal ($AUC = 0,895$), confirmant l'hypothèse que la projection sur un espace orthogonal débruité restaure l'efficacité de la séparation à marge maximale.

TABLEAU 1.4 – Performances moyennes (5-fold CV) — Configuration PCA + modèles tuned.

Modèle	Acc.	F1	AUC	Préc.	Rappel	Spéc.
KNN	0.769	0.780	0.821	0.800	0.775	—
SVM	0.831	0.835	0.895	0.896	0.807	—
RF	0.769	0.795	0.812	0.756	0.861	—
XGBoost	0.738	0.765	0.730	0.757	0.804	—




FIGURE 1.3 – Barplots comparatifs des performances — PCA features (21) + modèles Tuned.

La matrice de confusion normalisée du SVM (Figure 1.4) révèle une spécificité élevée pour les contrôles (86 % correctement classés) et une sensibilité satisfaisante pour l'AD (81 %). Les confusions résiduelles (14 % de faux positifs, 19 % de faux négatifs) s'expliquent par le chevauchement physiologique des profils EEG dans les stades précliniques de la maladie.




FIGURE 1.4 – Matrice de confusion du meilleur modèle — SVM PCA+Tuned .

1.2.2 Performances des modèles Tuned avec le jeu de données complet (316 features / sans PCA)

Après optimisation des hyperparamètres sur le jeu complet de 316 features (sans PCA), les performances sont rapportées Tableau 1.5. XGBoost domine cette configuration (accuracy = 0,815), illustrant la supériorité du boosting quand l'information discriminante est dispersée sur de nombreuses dimensions redondantes.

TABLEAU 1.5 – Performances moyennes (5-fold CV) — Jeu de données complet + modèles tuned.

Modèle	Acc.	F1	AUC	Préc.	Rappel	Spéc.
KNN	0.800	0.812	0.828	0.837	0.800	—
SVM	0.785	0.795	0.857	0.848	0.779	—
RF	0.800	0.820	0.862	0.799	0.857	—
XGBoost	0.815	0.824	0.857	0.845	0.829	—




FIGURE 1.5 – Barplots comparatifs des performances — Jeu de données complet + modèles tuned.

1.2.3 Importance des features : analyse du meilleur modèle par configuration

1.2.3.1 Configuration complète (316 features) — XGBoost Tuned.

L'analyse du gain de split XGBoost (Figure 1.6) révèle que les features dominantes appartiennent aux familles non-linéaires et spectrales. La dimension fractale de Higuchi (HFD) sur Fp1 occupe la première place (gain = 0,088), suivie de la variabilité de la puissance theta relative (0,084) et de la variabilité inter-époques de la puissance alpha relative (0,062). Cette hiérarchie confirme que la perte de complexité fractale frontale et le déséquilibre spectral slow/fast sont les signatures physiopathologiques les plus discriminantes de l'AD dans notre cohorte.

Les paramètres de Hjorth (mobilité, complexité) sur Fz, P3 et F3 figurent également parmi les 20 premières, indiquant une réduction de la dynamique du signal EEG dans ces régions frontales et pariétales. La cohérence theta F4–P4 et la DFA sur O2 complètent ce classement, suggérant une désorganisation de la connectivité inter-hémisphérique et une altération de la régularité temporelle du signal occipital.




FIGURE 1.6 – Top 20 features par gain de split — XGBoost Tuned (316 features).

1.2.3.2 Configuration PCA (21 composantes) — SVM Tuned.

La projection des importances sur les features originales (Figure 1.7) révèle que les composantes dominantes du SVM sont principalement construites à partir de la variabilité spectrale et de la complexité du signal. Les cinq premières positions sont occupées par l'écart-type de la puissance delta relative, l'écart-type de la puissance alpha relative (et sa variabilité inter-époques), ainsi que le coefficient de variation de la puissance alpha absolue. Cette concentration sur les bandes delta et alpha confirme que le SVM exploite principalement le déséquilibre slow-to-fast caractéristique de l'AD.




FIGURE 1.7 – Top 20 features originales par projection PCA — SVM PCA+Tuned.

1.3 Discussion

1.3.1 Complémentarité modèle–dimensionnalité :

La confrontation des configurations *modèles Tuned et évaluation sur 316 features* et *modèles Tuned + évaluation sur 21 composantes après PCA* révèle une interaction entre le modèle et la dimension du vecteur des features. Sur les 316 features complètes, XGBoost domine (accuracy = 0.815, ROC-AUC = 0.857) car son mécanisme de boosting agrège efficacement des variables faiblement informatives individuellement mais redondantes collectivement, tout en capturant les interactions non-linéaires entre familles de features (ex. ratio θ/α et entropie SVD). À l'inverse, après réduction PCA, le SVM à noyau RBF devient optimal (accuracy = 0.831, ROC-AUC = 0.895) : la projection sur 21 composantes orthogonales débruite l'espace et restaure la stabilité de la métrique euclidienne sous-jacente au noyau, rendant la frontière à marge maximale plus discriminante que l'agrégation arborescente dans un espace désormais

compact.

Cette inversion illustre que le choix algorithmique doit être adapté au régime dimensionnel : **boosting quand l’information est dispersée, séparateur à vaste marge quand elle est concentrée.**

1.3.2 Points forts

L’approche ML développée présente plusieurs atouts. Premièrement, le vecteur de caractéristiques multi-domaines (spectral, temporel, non-linéaire, cohérence) capture des signatures physiopathologiques complémentaires de l’AD. Deuxièmement, L’agrégation par sujet $[\mu, \sigma]$ sur les segments stabilise les descripteurs tout en préservant l’information de variabilité intra-sujet via les coefficients de variation. Troisièmement, l’optimisation des hyperparamètres par `RandomizedSearchCV` améliore de manière significative la généralisation, notamment pour les modèles à base d’arbres (RF, XGBoost) dont la profondeur et la régularisation sont sensibles à la colinéarité des features EEG.

1.3.3 Limites et perspectives

Plusieurs limites doivent être soulignées. La taille restreinte du dataset ($n = 88$) et le dés-équilibre inter-classes (36 AD vs 29 contrôles) limitent la puissance statistique et la robustesse des estimateurs. L’absence d’un jeu de test externe (validation sur un centre différent ou un protocole d’acquisition distinct) empêche d’évaluer la capacité de généralisation *inter-sites*, cruciale pour un déploiement clinique.

Sur le plan méthodologique, l’extraction manuelle de features, bien qu’interprétable, demande un savoir-faire domaine-spécifique et est sensible au prétraitement initial.

Enfin, l’intégration du groupe FTD ($n = 23$) dans une classification multiclasse constitue une perspective prometteuse.

Conclusion

Ce chapitre a décrit une approche Machine Learning complète pour la détection de la maladie d’Alzheimer à partir d’EEG de repos. Un vecteur de 316 caractéristiques multi-domaines a été extrait et évalué. Les résultats montrent que la meilleure performance est donnée par le modèle SVM entraîné sur 21 features gardés après PCA avec une accuracy = 83.1. Les biomarqueurs les plus discriminants — ratios θ/α , entropie SVD et puissances relatives δ — concordent avec la littérature neurophysiologique. Ces éléments valident la pertinence d’un pipeline ML interprétable comme baseline comparative pour l’approche Deep Learning présentée au chapitre suivant.

Chapitre 2

Approche hybride Deep Learning–SVM

Introduction

Le chapitre précédent a montré qu’un vecteur de 316 caractéristiques multi-domaines permet une discrimination AD/CN avec une accuracy de 83,1 %. Cette approche présente néanmoins deux limites : les descripteurs *handcrafted* ne capturent que les biomarqueurs que l’expert a explicitement formulés, et la classification reste binaire.

Ce chapitre présente une approche hybride qui lève ces deux limites : un réseau convolutif 1D (CNN) apprend automatiquement des représentations profondes inaccessibles aux formules manuelles, et leur fusion avec les features interprétables permet une classification **tri-classe** AD/FTD/CN sur les 88 sujets. L’approche est inspirée de [12].

2.1 Objectifs

1. Construire une architecture hybride fusionnant features expertes et embeddings CNN.
2. Réaliser une classification triclasse AD/FTD/CN sur 88 sujets.
3. Corriger le déséquilibre de classes (FTD minoritaire) par SMOTE.
4. Garantir une validation rigoureuse au niveau sujet (GroupKFold).
5. Interpréter les décisions du modèle par SHAP.

2.2 Présentation de la solution proposée

2.2.1 Architecture globale

Le pipeline s’organise en trois étapes (Figure 2.1) : prétraitement, extraction parallèle par deux voies, fusion et classification.




FIGURE 2.1 – Architecture globale du pipeline hybride Deep-SVM, inspirée de [12].

2.2.2 Étape 1 — Prétraitement

Le dataset ds004504 fournit des fichiers déjà prétraités dans le répertoire `derivatives/` [16] (filtrage, ré-référencement, ASR, ICA décrits au Chapitre 1). Nous chargeons ces fichiers via MNE-Python [15] et appliquons uniquement la **segmentation** :

- Fenêtres fixes de **4 secondes** sans chevauchement.
- Segments dont l’amplitude pic-à-pic dépasse $100\ \mu\text{V}$ rejetés.
- Chaque sujet fournit entre 50 et 180 segments valides.

L’absence de chevauchement garantit l’indépendance statistique des segments pour la validation GroupKFold.

2.2.3 Étape 2A — Features handcrafted

Nous retenons quatre groupes de features motivés par la physiopathologie de l’AD et de la FTD. Les formules de base (PSD Welch, cohérence spectrale, paramètres de Hjorth) ont été définies au Chapitre 1 ; seule l’entropie spectrale est nouvelle.

2.2.3.1 Entropie spectrale (SE)

L'entropie spectrale (distincte de l'entropie SVD du Chapitre 1) quantifie la complexité fréquentielle du signal en appliquant la mesure de Shannon à la PSD normalisée :

$$\text{SE} = - \sum_f p(f) \log_2 p(f), \quad p(f) = \frac{\hat{S}(f)}{\sum_{f'} \hat{S}(f')} \quad (2.1)$$

Une SE faible indique une énergie concentrée sur peu de fréquences (signal monotone, caractéristique de l'AD). Deux variantes sont calculées : **SE globale** sur [0,5–45] Hz, et **SE- α** sur [8–13] Hz — marqueur de perte de complexité alpha le plus reproductible dans la littérature [12].

Dimension : 2 valeurs/segment.

2.2.3.2 Cohérence alpha inter-hémisphérique (MAC)

Calculée sur les cinq paires symétriques F3-F4, C3-C4, P3-P4, O1-O2 et T3-T4. La MAC diminue dans AD (rupture des connexions inter-hémisphériques) et reste différenciable avec FTD (atteinte préférentielle frontale).

Dimension : 5 valeurs/segment.

2.2.4 Étape 2B — 1D-CNN pour l'extraction d'embeddings

Un réseau convolutionnel 1D applique des filtres apprenables le long de l'axe temporel du signal. Pour un filtre w de taille k appliqué au signal x :

$$(x * w)[t] = \sum_{i=0}^{k-1} x[t+i] w[i] \quad (2.2)$$

Contrairement aux features handcrafted, ces opérations apprennent directement depuis les données des représentations inaccessibles aux formules manuelles [12]. Notre réseau est délibérément léger pour éviter le surapprentissage sur 88 sujets (Figure 2.2).




FIGURE 2.2 – Architecture 1D-CNN pour l’extraction d’embeddings (128 dims), inspirée de [12].

Les filtres $k=5$ en première couche couvrent ≈ 50 ms à 500 Hz, soit une demi-période alpha — adapté à la détection des oscillations EEG dominantes. Le Dropout(0.5) assure une régularisation forte face au faible nombre de sujets. L’embedding de 128 dims est calibré pour équilibrer la contribution des deux voies lors de la fusion.

2.2.5 Étape 3 — Fusion, classification et validation




FIGURE 2.3 – Pipeline de fusion, normalisation, rééquilibrage et classification [12].

2.2.5.1 Normalisation z-score.

Les features handcrafted (puissance en $\mu V^2/Hz$) et les embeddings CNN (activations arbitraires) opèrent sur des échelles incompatibles. La transformation $z = (x - \mu)/\sigma$, calculée sur

le fold d’entraînement uniquement, équilibre leurs contributions au SVM.

2.2.5.2 PCA — 64 composantes.

Après concaténation (146 dims), la PCA réduit l’espace à 64 composantes, valeur dynamiquement sélectionnée comme optimale par la recherche sur grille (*grid search*) interne. Afin de garantir une évaluation rigoureuse et d’éviter toute fuite de données (*data leakage*), cette transformation est encapsulée au sein du pipeline d’apprentissage : la matrice de projection PCA est calculée **strictement pendant l’entraînement** (sur les plis internes), puis appliquée telle quelle aux données de test. Son rôle ici est différent du Chapitre 1 : elle **fusionne** deux espaces hétérogènes (features expertes et embeddings profonds) plutôt que de compresser un seul espace.

2.2.5.3 SMOTE [12].

SMOTE génère des exemples synthétiques de la classe minoritaire (FTD) par interpolation entre voisins. Appliqué *strictement dans les folds d’entraînement* pour éviter toute fuite vers le jeu de test [12].

2.2.5.4 SVM-RBF ($C=1$, $\gamma=0,01$).

Hyperparamètres sélectionnés par *grid search* en boucle interne. Le SVM est préféré à une couche dense finale pour sa meilleure généralisation sur petits datasets. La stratégie One-vs-Rest étend la classification au cas triclasse.

2.2.5.5 Validation croisée imbriquée GroupKFold (5 plis).

Toutes les époques d’un sujet restent dans le même pli, éliminant le biais de corrélation intra-sujet identifié comme limite au Chapitre 1. Cela simule la généralisation clinique réelle (nouveaux patients).

2.2.6 Explicabilité par SHAP

SHAP (*SHapley Additive exPlanations*) [12] attribue à chaque feature une contribution ϕ_i à la prédiction en s’appuyant sur la théorie des jeux coopératifs :

$$\phi_i = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f(S \cup \{i\}) - f(S)] \quad (2.3)$$

Appliqué au SVM dans l’espace PCA, SHAP identifie les composantes décisives.

Par rétroprojection $\mathbf{W}_k^\top$, celles-ci sont reliées aux canaux EEG et bandes fréquentielles d’origine. D’après [12], PC5, PC6 et PC14 — correspondant aux perturbations de cohérence fronto-temporale et aux oscillations alpha/thêta — sont les composantes les plus discriminantes entre

AD et les autres groupes.

2.3 Résultats et discussion

2.3.1 Performances de classification

Les performances ont été mesurées à la fois au niveau des segments (époches de 4 secondes) et au niveau global de l'individu (sujet).

TABLEAU 2.1 – Comparaison des performances de classification entre l'implémentation proposée et l'article de référence.

Métrique	Papier de référence [12]	Notre implémentation
Nombre d'époques	848	8 346
Accuracy (Époque)	Non précisé	$42,28 \pm 3,73 \%$
F1-Macro (Époque)	Non précisé	$41,26 \pm 3,77 \%$
AUC OvO (Époque)	Non précisé	$60,00 \pm 3,28 \%$
Accuracy (Sujet)	$\sim 94,5 \%$	51,16 %
F1-Macro (Sujet)	$\sim 0,95$	45,85 %

2.3.2 Importance des caractéristiques

Afin d'ouvrir la « boîte noire » du SVM, nous avons extrait les valeurs SHAP.

La Figure 2.4 illustre l'importance globale des composantes principales, identifiant la composante PC3 comme le pilier décisionnel majeur du modèle.




FIGURE 2.4 – Explicabilité SHAP : Importance globale des composantes sur l'ensemble des diagnostics.

La Figure 2.5 détaille ensuite cet impact par pathologie. On observe que certaines composantes agissent comme de puissants biomarqueurs (impact positif, en rouge) pour les maladies neurodégénératives, tandis que d'autres, représentant probablement des rythmes cérébraux sains, orientent fortement le diagnostic vers la classe contrôle (CN).




FIGURE 2.5 – Explicabilité SHAP : Impact directionnel (positif/négatif) détaillé par classe diagnostique (AD, FTD, CN).

2.3.3 Analyse comparative des performances

L'écart entre nos résultats (51,16 % d'accuracy par sujet) et ceux de l'étude de référence ($\sim 94,5\%$) [12] s'explique par des choix méthodologiques stricts, visant à évaluer le modèle dans des conditions cliniques réalistes :

- **Volume de données** : Le découpage du signal continu en fenêtres de 4 secondes génère logiquement environ 100 époques par patient, d'où notre total de 8 346 époques. L'étude de référence (848 époques) s'appuie très probablement sur un sous-ensemble sélectionné. Évaluer le modèle sur un volume dix fois supérieur introduit une variabilité naturelle qui impacte les métriques brutes.
- **Validation stricte (GroupKFold)** : Pour simuler l'arrivée d'un nouveau patient, notre validation isole strictement les sujets. Le modèle est testé sur des cerveaux qu'il n'a formellement jamais vus, empêchant la mémorisation de la signature EEG globale d'un individu. Cette méthode produit des scores plus conservateurs, mais garantit une véritable généralisation clinique.
- **Confinement du SMOTE** : La génération de données synthétiques a été confinée exclusivement aux plis d'entraînement, évitant toute contamination des données de test.

Une précision de 51,16 % au niveau du sujet sur un problème triclasse (AD, FTD, CN), évaluée sur un volume de données totalement inconnues, constitue ainsi une ligne de base robuste. Elle confirme que notre modèle s'appuie sur d'authentiques biomarqueurs neurophysiologiques.

2.3.4 Discussion et validation clinique

Les résultats quantitatifs démontrent la robustesse mathématique du pipeline. Cependant, la véritable valeur d'un outil d'aide au diagnostic réside dans sa cohérence neurophysiologique.

— Dynamique temporelle des anomalies

Contrairement aux approches classiques qui moyennent l'information sur l'ensemble de

l'époque, notre analyse temporelle SHAP (Figure 2.6) révèle le moment exact où le modèle détecte l'information discriminante.

Chez les patients sains (CN), l'importance décisionnelle est relativement distribuée dans le temps, traduisant un rythme de fond stable et continu. À l'inverse, pour les classes AD et FTD, le modèle réagit à des pics soudains et très localisés dans le temps. Cela suggère que le réseau de neurones 1D-CNN a appris à détecter des événements épisodiques anormaux (comme des bouffées d'ondes lentes), caractéristiques des processus neurodégénératifs.




FIGURE 2.6 – Dynamique temporelle de l'importance SHAP sur une époque de 4 secondes pour chaque classe.

— Redécouverte autonome de la neuroanatomie (Topomaps)




FIGURE 2.7 – Cartographie topographique de l'attention du modèle. Les zones en rouge sombre indiquent les régions cérébrales les plus déterminantes pour la classification.

La Figure 2.7 présente la rétroprojection spatiale des valeurs SHAP sur le scalp. Bien que ces cartes permettent de visualiser les zones d'intérêt du modèle, la différence visuelle entre les classes AD, FTD et CN reste subtile.

Cette observation est cohérente avec les performances globales du modèle (Accuracy $\approx 51\%$) : avec une précision modérée, le classifieur n'a pas encore appris à isoler des signatures spatiales radicalement distinctes pour chaque pathologie. Néanmoins, il est intéressant de noter que le modèle cible les régions temporo-pariétales, zones cliniquement critiques dans la neurodégénérescence [7]. Ce comportement confirme que le classifieur capte déjà des marqueurs neuroanatomiques pertinents.

2.3.5 Points forts

- **Intégrité méthodologique (Zero Data Leakage)** : L'évaluation imbriquée strictement par sujet (GroupKFold) Garantit une généralisation clinique fiable en évitant les biais courants de la littérature.
- **Transparence clinique (Boîte blanche)** : L'intégration de SHAP et des topomaps brise l'opacité du Deep Learning. L'algorithme prouve de manière autonome qu'il cible les bons biomarqueurs.
- **Synergie des caractéristiques** : La fusion entre l'expertise humaine (descripteurs *hand-crafted*) et l'extraction automatique (1D-CNN) capture un profil EEG riche et complémentaire.

2.3.6 Limites et perspectives

- **Coût computationnel** : La combinaison d'une validation croisée imbriquée, du rééquilibrage SMOTE et de l'approximation SHAP exige d'importantes ressources de calcul pour l'entraînement.
- **Taille de la cohorte** : Malgré un grand volume d'époques, 88 patients constituent un échantillon restreint. Une validation sur des bases de données multicentriques est indispensable pour confirmer la robustesse du modèle.

2.4 Conclusion

Ce chapitre a validé une architecture hybride (1D-CNN + SVM) pour la classification tri-classe (AD, FTD, CN) à partir de signaux EEG. L'application d'une validation croisée isolant rigoureusement les sujets a permis d'éviter les fuites de données et d'établir une ligne de base clinique réaliste.

L'apport majeur de ce travail réside dans son interprétabilité grâce à l'algorithme SHAP. En ciblant de manière autonome les régions temporo-pariétales, le modèle prouve qu'il ne mémorise pas un simple bruit de fond, mais qu'il identifie une véritable signature de la neurodégénérescence. Ce pipeline réconcilie ainsi la puissance de l'intelligence artificielle avec l'exigence de transparence indispensable au milieu médical.

Conclusion générale et perspectives

Ce rapport a présenté un projet de détection automatique de la maladie d’Alzheimer à partir de signaux EEG en repos yeux fermés.

L’approche Machine Learning développée au chapitre 1 démontre qu’un vecteur de caractéristiques multi-domaines, alliant descripteurs spectraux, temporels, de cohérence et non-linéaires, permet une discrimination binaire Alzheimer versus contrôle avec des performances encourageantes. L’optimisation des hyperparamètres contribue à la robustesse du pipeline face à la faible taille de l’échantillon. Les features les plus discriminantes — notamment les ratios spectraux θ/α et les mesures d’entropie — s’alignent sur les biomarqueurs EEG établis dans la littérature.

L’approche hybride Deep Learning–SVM, détaillée au chapitre 2, étend ce travail à une classification triclassée (AD, FTD, CN) en fusionnant des descripteurs manuels avec des représentations profondes (1D-CNN). Évaluée selon un protocole strict isolant les patients (*GroupKFold*), elle garantit une estimation réaliste des performances en évitant la fuite de données. L’analyse SHAP démontre que le modèle cible de manière autonome les régions temporo-pariétales, validant la détection d’une véritable signature neurodégénérative. À l’avenir, l’évaluation sur des cohortes multicentriques et l’exploration d’architectures modélisant la connectivité spatiale (Transformers, GNN) permettront de rapprocher cet outil d’un déploiement clinique.

Bibliographie

- [1] P. D. Welch, “The use of fast Fourier transform for the estimation of power spectra : a method based on time averaging over short, modified periodograms,” *IEEE Transactions on Audio and Electroacoustics*, vol. 15, no. 2, pp. 70–73, 1967. <https://doi.org/10.1109/TAU.1967.1161901>
- [2] B. Hjorth, “EEG analysis based on time domain properties,” *Electroencephalography and Clinical Neurophysiology*, vol. 29, no. 3, pp. 306–310, 1970. [https://doi.org/10.1016/0013-4694\(70\)90143-4](https://doi.org/10.1016/0013-4694(70)90143-4)
- [3] C.-K. Peng, S. V. Buldyrev, A. L. Goldberger, S. Havlin, F. Sciortino, M. Simons, and H. E. Stanley, “Mosaic organization of DNA nucleotides,” *Physical Review E*, vol. 49, no. 2, p. 1685, 1994. <https://doi.org/10.1103/PhysRevE.49.1685>
- [4] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed. New York, NY, USA : Springer, 2002. <https://doi.org/10.1007/b98835>
- [5] A. Gramfort *et al.*, “MNE software for processing MEG and EEG data,” *NeuroImage*, vol. 86, pp. 446–460, 2014. <https://doi.org/10.1103/PhysRevE.49.1685>
- [6] M. Sabeti, S. Katebi, and R. Boostani, “Entropy and complexity measures for EEG signal classification of schizophrenia and control participants,” *Artificial Intelligence in Medicine*, vol. 47, no. 3, pp. 263–274, 2009. <https://pubmed.ncbi.nlm.nih.gov/19403281/>
- [7] A. Serrano-Pozo, M. P. Frosch, E. Masliah, and B. T. Hyman, “Neuropathological alterations in Alzheimer disease,” *Cold Spring Harbor Perspectives in Medicine*, vol. 1, no. 1, p. a006189, 2011. <https://doi.org/10.1101/cshperspect.a006189>
- [8] A. H. Al-Nuaimi, E. Jammeh, L. Sun, and E. Ifeachor, “Higuchi fractal dimension of the electroencephalogram as a biomarker for early detection of Alzheimer’s disease,” *IEEE Access*, vol. 5, pp. 3042–3051, 2017.
- [9] P. Blin *et al.*, “EEG Dataset for Alzheimer’s Disease and Frontotemporal Dementia (Open-Neuro ds004504, v1.0.7),” 2023. [Online]. Available : <https://openneuro.org/datasets/ds004504/versions/1.0.7>
- [10] GBD 2021 Forecasting Collaborators, “Global, regional, and national burden of dementia

- in 204 countries and territories, 1990–2021 : a systematic analysis for the Global Burden of Disease Study 2021,” *The Lancet Global Health*, vol. 12, no. 5, pp. e721–e735, 2024. <https://pubmed.ncbi.nlm.nih.gov/40540265/>
- [11] World Health Organization, “Dementia,” 2021. [Online]. Available : <https://www.who.int/news-room/fact-sheets/detail/dementia>
- [12] F. Akbar, Y. Alkhrijah, S.M. Usman, S. Khalid, I. Ihsan, and M.A. Alawad, “A deep-SVM hybrid framework with enhanced EEG feature engineering and SHAP-based explainability for Alzheimer’s classification,” *Scientific Reports*, 2026. DOI : <https://doi.org/10.1038/s41598-026-43431-w>.
- [13] H. Zhang et al., “The significance of EEG alpha oscillation spectral power and beta oscillation phase synchronization for diagnosing probable Alzheimer disease,” *Frontiers in Aging Neuroscience*, 2021. DOI : <https://doi.org/10.3389/fnagi.2021.631587>.
- [14] X. Zheng et al., “Diagnosis of Alzheimer’s disease via resting-state EEG : integration of spectrum, complexity, and synchronization features,” *Frontiers in Aging Neuroscience*, 2023. DOI : <https://doi.org/10.3389/fnagi.2023.1288295>.
- [15] A. Gramfort et al., “MEG and EEG data analysis with MNE-Python,” *Frontiers in Neuroscience*, vol. 7, p. 267, 2013. DOI : <https://doi.org/10.3389/fnins.2013.00267>.
- [16] A. Miltiadous, K.D. Tzimourta, T. Afrantou et al., “EEG dataset for Alzheimer’s disease and frontotemporal dementia (OpenNeuro ds004504, v1.0.7),” 2023. [Online]. Available : <https://openneuro.org/datasets/ds004504/versions/1.0.7>.