

Titre du Projet : Diagnostic automatisé de la maladie d'Alzheimer par EEG : Étude comparative entre modèles de Machine Learning (XGBoost, k-NN, SVM) et architectures de Deep Learning (CNN-LSTM).

1. Description du sujet

Le projet propose de comparer deux approches d'IA pour détecter les biomarqueurs de la maladie d'Alzheimer à partir de signaux EEG. Nous évaluerons l'efficacité de l'extraction manuelle de caractéristiques cliniques (ML) face à l'apprentissage automatique de représentations end-to-end (DL).

2. Détails de l'Approche Machine Learning :

L'approche ML repose sur l'idée que le cerveau d'un patient Alzheimer présente des anomalies physiques connues (ralentissement des ondes, perte de puissance).

- **Extraction de Caractéristiques (Feature Extraction) :**
 - **Domaine Fréquentiel :** Utilisation de la méthode de **Welch** pour calculer la Puissance Spectrale (PSD) dans les bandes δ (0.5-4 Hz), θ (4-8 Hz), α (8-13 Hz) et β (13-30 Hz). On cherche le "spectral slowing" (augmentation des ondes lentes θ et diminution des ondes rapides α).
 - **Statistiques Temporelles :** Calcul de la variance, de l'asymétrie (skewness) et du kurtosis pour chaque canal afin de quantifier l'instabilité du signal.
- **Modèles de Classification :**
 - **XGBoost (Extreme Gradient Boosting) :** Un algorithme d'arbres de décision boostés qui va classer les patients en créant une hiérarchie d'importance sur les caractéristiques extraites.
 - **k-NN (k-Nearest Neighbors) :** Un modèle basé sur la proximité dans l'espace des caractéristiques (on compare la signature spectrale d'un nouveau patient à celle de la base de données).
 - **SVM (Support Vector Machine) :** Utilisé avec un noyau linéaire pour trouver la frontière de décision optimale entre les signatures cérébrales saines et pathologiques.
- **Technologies :** Scikit-learn, XGBoost, Pandas.

3. Détails de l'Approche Deep Learning :

L'approche DL traite l'EEG comme une série temporelle brute pour capturer des motifs que l'œil humain ou les statistiques simples ne voient pas.

- **Préparation des Tenseurs** : Le signal est segmenté en époques (ex: fenêtres de 2s) et normalisé par **Z-score** pour stabiliser l'entraînement.
- **Architectures Implémentées** :
 - **EEGNet (CNN Spatial)** : Utilise des convolutions temporelles (pour les fréquences) suivies de convolutions "Depthwise" (pour capturer les relations spatiales entre les électrodes).
 - **Hybride CNN-LSTM** :
 - **Bloc CNN** : Agit comme un extracteur automatique de caractéristiques spatiales.
 - **Bloc LSTM (Mémoire)** : Le bloc CNN extrait les caractéristiques spatiales entre les électrodes, tandis que le bloc **LSTM (Long Short-Term Memory)** analyse la dynamique et la mémoire temporelle du signal.

Technologies : PyTorch ou TensorFlow, MNE-Python

4. Cadre d'Évaluation et Validation

Afin d'assurer la fiabilité médicale des résultats, le projet suivra un protocole strict :

Mesures de Performance:

Le succès des modèles ne sera pas jugé uniquement sur l'Accuracy, mais sur une analyse fine de la matrice de confusion :

- **Sensibilité (Recall)** : Capacité critique à détecter tous les patients atteints (minimiser les Faux Négatifs).
- **Spécificité** : Capacité à identifier correctement les sujets sains (minimiser les Faux Positifs).
- **F1-Score & AUC-ROC** : Mesures de robustesse globale de la classification.

Datasets :

OpenNeuro (ds004504) — Données EEG brutes.

Kaggle : Alzheimer's Disease EEG Signal Dataset.

